

# **Stochastik SS 2019**

Dozent: Prof. Dr. ANITA BEHME

11. April 2019

# *Inhaltsverzeichnis*

<b>I</b>	<b>Grundbegriffe der Wahrscheinlichkeitstheorie</b>	<b>4</b>
1	Wahrscheinlichkeitsräume . . . . .	4
2	Zufallsvariablen . . . . .	8
<b>II</b>	<b>Erste Standardmodelle der Wahrscheinlichkeitstheorie</b>	<b>13</b>
1	Diskrete Gleichverteilungen . . . . .	13
2	Urnenmodelle . . . . .	13
2.1	Urnenmodell mit Zurücklegen: Multinomial-Verteilung . . . . .	14
2.2	Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung . . . . .	16
3	POISSON-Approximation und POISSON-Verteilung . . . . .	16
<b>III</b>	<b>Bedingte Wahrscheinlichkeiten und (Un)-abhängigkeit</b>	<b>18</b>
1	Bedingte Wahrscheinlichkeiten . . . . .	18
<b>IV</b>	<b>Test</b>	<b>20</b>
	<b>Anhang</b>	<b>22</b>
	<b>Index</b>	<b>22</b>

# *Vorwort*

# *Literatur*

- *Georgii*: Stochastik (5. Auflage)
- *Schilling*: Wahrscheinlichkeit (1. Auflage)
- *Bauer*: Wahrscheinlichkeitstheorie (5. Auflage) (sehr maßtheoretisch!)

Ohne Maßtheorie!

- *Krengel*: Einführung in die Wahrscheinlichkeitstheorie und Statistik
- *Dehling & Haupt*: Einführung in die Wahrscheinlichkeitstheorie und Statistik

# *Was ist Stochastik?*

Altgriechisch Stochastikos ( $\sigma\tau\omicron\chi\alpha\sigma\tau\iota\kappa\acute{o}\varsigma$ ) und bedeutet sinngemäß “scharfsinnig in Vermuten”.

Fragestellung insbesondere aus Glücksspiel, Versicherungs-/Finanzmathematik, überall da wo Zufall/Risiko / Chance auftauchen.

Was ist Stochastik?

- Beschreibt zufällige Phänomene in einer exakten Sprache!  
Beispiel: “Beim Würfeln erscheint jedes sechste Mal (im Schnitt) eine 6.”  $\rightarrow$  Gesetz der großen Zahlen ( $\nearrow$  später)
- Lässt sich mathematische Stochastik in zwei Teilgebiete unterteilen  
Wahrscheinlichkeitstheorie (Wahrscheinlichkeitstheorie) & Statistik
  - *Wahrscheinlichkeitstheorie*: Beschreibt und untersucht konkret gegebene Zufallssituationen.
  - *Statistik*: Zieht Schlussfolgerungen aus Beobachtungen.

Statistik benötigt Modelle der Wahrscheinlichkeitstheorie. Wahrscheinlichkeitstheorie benötigt die Bestätigung der Modelle durch Statistik.

In diesem Semester konzentrieren wir uns nur auf die Wahrscheinlichkeitstheorie!

## Kapitel I

# *Grundbegriffe der Wahrscheinlichkeitstheorie*

## 1. Wahrscheinlichkeitsräume

### Ergebnisraum

Welche der möglichen Ausgänge eines zufälligen Geschehens interessieren uns?

Würfeln? Augenzahl, nicht die Lage und die Fallhöhe

#### **Definition 1.1 (Ergebnisraum)**

Die Menge der relevanten Ergebnisse eines Zufallsgeschehens nennen wir Ergebnisraum und bezeichnen diesen mit  $\Omega$ .

#### ■ Beispiel

- Würfeln:  $\Omega = \{1, 2, \dots, 6\}$
- Wartezeiten:  $\Omega = \mathbb{R}_+ = [0, \infty)$  (überabzählbar!)

### Ereignisse

Oft interessieren wir uns gar nicht für das konkrete Ergebnis des Zufallsexperiments, sondern nur für das Eintreten gewisser Ereignisse.

#### ■ Beispiel

- Würfeln: Zahl ist  $\geq 3$
- Wartezeit: Wartezeit  $\leq 5$  Minuten

→ Teilmenge des Ereignisraums, also Element der Potenzmenge  $\mathcal{P}(\Omega)$ , denen eine Wahrscheinlichkeit zugeordnet werden kann, d.h. welche messbar (mb) sind.

#### **Definition 1.2 (Ereignisraum, messbarer Raum)**

Sei  $\Omega \neq \emptyset$  ein Ergebnisraum und  $\mathcal{F}$  eine  $\sigma$ -Algebra auf  $\Omega$ , d.h. eine Familie von Teilmenge von  $\Omega$ , sodass

1.  $\Omega \in \mathcal{F}$
2.  $A \in \mathcal{F} \Rightarrow A^C \in \mathcal{F}$
3.  $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{i \geq 1} A_i \in \mathcal{F}$

Dann heißt  $(\Omega, \mathcal{F})$  Ereignisraum bzw. messbarer Raum.

### Wahrscheinlichkeiten

Ordne Ereignissen Wahrscheinlichkeiten zu mittels der Abbildung

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$$

sodass

$$\text{Normierung } \mathbb{P}(\Omega) = 1 \quad (\text{N})$$

$$\sigma\text{-Additivität für paarweise disjunkte Ereignisse } A_1, A_2, \dots \in \mathcal{F} \Rightarrow \mathbb{P}\left(\bigcup_{i \geq 1} A_i\right) = \sum_{i \geq 1} \mathbb{P}(A_i) \quad (\text{A})$$

(N), (A) und die Nichtnegativität von  $\mathbb{P}$  werden als KOLMOGOROVsche Axiome bezeichnet (nach Kolmogorov: Grundbegriffe der Wahrscheinlichkeitstheorie, 1933)

**Definition 1.3 (Wahrscheinlichkeitsmaß, Wahrscheinlichkeitsverteilung)**

Sei  $(\Omega, \mathcal{F})$  ein Ereignisraum und  $\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$  eine Abbildung mit Eigenschaften (N) und (A).

Dann heißt  $\mathbb{P}$  Wahrscheinlichkeitsmaß oder auch Wahrscheinlichkeitsverteilung.

Aus der Definition folgen direkt:

**Satz 1.4 (Rechenregeln für W-Maße)**

Sei  $\mathbb{P}$  ein W-Maß, Ereignisse  $(\Omega, \mathcal{F}), A, B, A_1, A_2, \dots \in \mathcal{F}$ . Dann gelten:

1.  $\mathbb{P}(\emptyset) = 0$
2. Monotonie:  $A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$
3. endliche  $\sigma$ -Additivität:  $\mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) = \mathbb{P}(A) + \mathbb{P}(B)$  und insbesondere  $\mathbb{P}(A) + \mathbb{P}(A^C) = 1$
4.  $\sigma$ -Subadditivität:

$$\mathbb{P}\left(\bigcup_{i \geq 1} A_i\right) \leq \sum_{i \geq 1} \mathbb{P}(A_i)$$

5.  $\sigma$ -Stetigkeit: Wenn  $A_n \uparrow A$  (d.h.  $A_1 \subseteq A_2 \subseteq \dots$  und  $A = \bigcup_{i=1}^{\infty} (A_i)$ ) oder  $A_n \downarrow A$ , so gilt:

$$\mathbb{P}(A_n) \longrightarrow \mathbb{P}(A), n \rightarrow \infty$$

*Beweis.* In der Vorlesung wurde nur auf Schillings MINT Vorlesung verwiesen. Der folgende Beweis wurde ergänzt.

Beweise erst folgende Aussage:  $A \cap B = \emptyset \implies \mathbb{P}(A \uplus B) = \mathbb{P}(A) + \mathbb{P}(B)$ .

Es kann  $\sigma$ -Additivität verwendet werden, indem "fehlende" Mengen durch  $\emptyset$  ergänzt werden:

$$\mathbb{P}(A \uplus B) = \mathbb{P}(A \uplus B \uplus \emptyset \uplus \emptyset \dots) = \mathbb{P}(A) + \mathbb{P}(B) + \mathbb{P}(\emptyset) + \dots = \mathbb{P}(A) + \mathbb{P}(B),$$

wobei Maßeigenschaften verwendet wurden.

1. Definition des Maßes.

2. Da  $A \subseteq B$  ist auch  $B = A \uplus (B \setminus A) = A \uplus (B \setminus (A \cap B))$ . Wende wieder Aussage von oben an, damit folgt

$$\mathbb{P}(B) = \mathbb{P}(A \uplus (B \setminus A)) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A) \quad (*)$$

3. Zerlege  $A \cup B$  geschickt, dann sieht man mit oben gezeigter Aussage und  $(*)$

$$\begin{aligned} \mathbb{P}(A \cup B) + \mathbb{P}(A \cap B) &= \mathbb{P}(A \uplus (B \setminus (A \cap B))) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B \setminus (A \cap B)) + \mathbb{P}(A \cap B) \\ &= \mathbb{P}(A) + \mathbb{P}(B). \end{aligned}$$

Im letzten Schritt wurde  $(*)$  verwendet.

4. Folgt aus endlicher  $\sigma$ -Additivität, da  $\mathbb{P}\left(\bigcap_{i \geq 1} A_i\right) \geq 0$ .

5. Definiere  $F_1 := A_1, F_2 := A_2 \setminus A_1, \dots, F_{i+1} := A_{i+1} \setminus A_i$ . Die  $F_i$  Mengen sind paarweise disjunkt und damit folgt für  $m \rightarrow \infty$

$$A_m = \biguplus_{i=1}^m F_i \Rightarrow A = \biguplus_{i=1}^{\infty} F_i = \biguplus_{i=1}^{\infty} A_i$$

und

$$\mathbb{P}(A) = \mathbb{P}\left(\biguplus_{i=1}^{\infty} F_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(F_i) = \lim_{m \rightarrow \infty} \lim_{m \rightarrow \infty} \mathbb{P}\left(\biguplus_{i=1}^m F_i\right) = \lim_{m \rightarrow \infty} \lim_{m \rightarrow \infty} \mathbb{P}(A_m). \quad \square$$

### ■ Beispiel 1.5

Für ein beliebiges Ereignisraum  $(\Omega, \mathcal{F})$  ( $\Omega \neq \emptyset$ ) und eine beliebiges Element  $\xi \in \Omega$  definiere

$$\delta_{\xi}(A) := \begin{cases} 1 & \xi \in A \\ 0 & \text{sonst} \end{cases}$$

eine (degeneriertes) W-Maß auf  $(\Omega, \mathcal{F})$ , welches wir als DIRAC-Maß oder DIRAC-Verteilung bezeichnen.

### ■ Beispiel 1.6

Würfeln mit fairem, 6-(gleich)seitigem Würfel mit Ergebnismenge  $\Omega = \{1, \dots, 6\}$  und Ereignisraum  $\mathcal{F} = \mathcal{P}(\Omega)$  setzen wir als Symmetriegründen

$$\mathbb{P}(A) = \frac{\#A}{6}.$$

(Wobei  $\#A$  oder auch  $|A|$  die Kardinalität von  $A$  ist.) Das definiert ein W-Maß.

### ■ Beispiel 1.7

Wartezeit an der Bushaltestelle mit Ergebnisraum  $\Omega = \mathbb{R}_+$  und Ereignisraum BORELSche  $\sigma$ -Algebra  $\mathcal{B}(\mathbb{R}_+) = \mathcal{F}$ . Eine möglichen W-Maß können wir dann durch

$$\mathbb{P}(A) = \int_A \lambda e^{-\lambda x} dx$$

für einen Parameter  $\lambda > 0$  festlegen. (Offenbar gilt  $\mathbb{P}(\Omega) = 1$  und die  $\sigma$ -Additivität aufgrund der



Additivität des Integrals.) Wir bezeichnen diese Maß als Exponentialverteilung. (Warum gerade dieses Maß für Wartezeiten gut geeignet ist  $\nearrow$  später)

**Satz 1.8 (Konstruktion von Wahrscheinlichkeitsmaßen durch Dichten)**

Sei  $(\Omega, \mathcal{F})$  ein Ereignisraum.

- $\Omega$  abzählbar,  $\mathcal{F} = \mathcal{P}(\Omega)$ : Sei  $\rho = (\rho(\omega))_{\omega \in \Omega}$  eine Folge in  $[0, 1]$  in  $\sum_{\omega \in \Omega} \rho(\omega) = 1$ , dann definiert

$$\mathbb{P}(A) = \sum_{\omega \in \Omega} \rho(\omega), A \in \mathcal{F}$$

ein (diskretes) Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$ .  $\rho$  wird als Zähldichte bezeichnet.

- Umgekehrt definiert jedes Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$  definiert Folge  $\rho(\omega) = \mathbb{P}(\{\omega\}), \omega \in \Omega$  eine Folge  $\rho$  mit den obigen Eigenschaften.
- $\Omega \subset \mathbb{R}^n, \mathcal{F} = \mathcal{B}(\Omega)$ : Sei  $\rho : \Omega \rightarrow [0, \infty)$  eine Funktion, sodass

$$1. \int_{\Omega} \rho(x) dx = 1$$

$$2. \{x \in \Omega : f(x) \leq c\} \in \mathcal{B}(\Omega) \text{ für alle } c > 0$$

dann definiert  $\rho$  ein Wahrscheinlichkeitsmaß  $\mathbb{P}$  auf  $(\Omega, \mathcal{F})$  durch

$$\mathbb{P}(A) = \int_A \rho(x) dx = \int_A \rho d\lambda, \quad A \in \mathcal{B}(\Omega).$$

Das Integral interpretieren wir stets als Lebesgue-Integral bzw. Lebesgue-Maß  $\lambda$ .  $\rho$  bezeichnet wir als Dichte, Dichtefunktion/Wahrscheinlichkeitsdichte von  $\mathbb{P}$  und nennen ein solches  $\mathbb{P}$  (absolut)stetig (bzgl. denn Lebesgue-Maß).

*Beweis.* • Der diskrete Fall ist klar.

- Im stetigen Fall folgt die Behauptung aus den bekannten Eigenschaften des Lebesgue-Integrals ( $\nearrow$  Schilling MINT, Lemma 8.9)  $\square$

► **Bemerkung**

- Die Eineindeutige Beziehung zwischen Dichte und Wahrscheinlichkeitsmaß überträgt sich nicht auf den stetigen Fall.
  - Nicht jedes Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega)), \Omega \subset \mathbb{R}^n$  besitzt eine Dichte.
  - Zwei Dichtefunktionen definieren dasselbe Wahrscheinlichkeitsmaß, wenn sie sich nur auf einer Menge von Lebesgue-Maß 0 unterscheiden.
- Jede auf  $\Omega \subset \mathbb{R}^n$  definiert Dichtefunktion  $\rho$  lässt sich auf ganz  $\mathbb{R}^n$  fortsetzen durch  $\rho(x) = 0, x \notin \Omega$ . Das erzeugte Wahrscheinlichkeitsmaß auf  $(\mathbb{R}^n, \mathcal{B}(\Omega))$  lässt mit den Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega))$  identifizieren.
- Mittels Dirac-Maß  $\delta_x$  können auch jedes diskrete Wahrscheinlichkeitsmaß auf  $\Omega \subset \mathbb{R}^n$  als

Wahrscheinlichkeitsmaß auf  $\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n)$  interpretieren

$$\mathbb{P}(A) = \sum_{\omega \in A} \rho(\omega) = \int_A d\left(\sum_{\omega \in \Omega} \rho(\omega) \delta_\omega\right)$$

stetige und diskrete Wahrscheinlichkeitsmaße lassen sich kombinieren z.B.

$$\mathbb{P}(A) = \frac{1}{2} \delta_0 + \frac{1}{2} \int_A \mathbb{1}_{[0,1]}(x) dx, A \in \mathcal{B}(\mathbb{R})$$

ein Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ .

Abschließend erinnern wir uns an:

**Satz 1.9 (Eindeutigkeitssatz für Wahrscheinlichkeitsmaße)**

Sei  $(\Omega, \mathcal{F})$  Ereignisraum und  $\mathbb{P}$  ein Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F})$ . Sei  $\mathcal{F} = \sigma(\mathcal{G})$  für ein  $\cap$ -stabiles Erzeugendensystem  $\mathcal{G} \subset \mathcal{P}(\Omega)$ . Dann ist  $\mathbb{P}$  bereits durch seine Einschränkung  $\mathbb{P}|_{\mathcal{G}}$  eindeutig bestimmt.

*Beweis.* ↗ Schilling MINT, Satz 4.5. □

Insbesondere definiert z.B.

$$\mathbb{P}([0, a]) = \int_0^a \lambda e^{-\lambda x} dx = 1 - e^{-\lambda a}, a > 0$$

bereits die Exponentialverteilung aus Beispiel 1.7.

**Definition 1.10 (Gleichverteilung)**

Ist  $\Omega$  endlich, so heißt das Wahrscheinlichkeitsmaß mit konstanter Zähldichte  $\rho(\omega) = 1/|\Omega|$  die (diskrete) Gleichverteilung auf  $\Omega$  und wird mit  $U(\Omega)$  notiert ( $U = \text{Uniform}$ ). Ist  $\Omega \subset \mathbb{R}^n$  eine Borelmenge mit Lebesgue-Maß  $0 < \lambda^n(\Omega) < \infty$  so heißt das Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{B}(\Omega))$  mit konstanter Dichtefunktion  $\rho(x) = 1/\lambda^n(x)$  die (stetige) Gleichverteilung auf  $\Omega$ . Sie wird ebenso mit  $U(\Omega)$  notiert.

**WRäume**

**Definition 1.11 (Wahrscheinlichkeitsraum)**

Ein Tripel  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $\Omega, \mathcal{F}$  Ereignisraum und  $\mathbb{P}$  Wahrscheinlichkeitsmaß auf  $(\Omega, \mathcal{F})$ , nennen wir

Wahrscheinlichkeitsraum.

## 2. Zufallsvariablen

Zufallsvariablen dienen dazu von einem gegebenen Ereignisraum  $(\Omega, \mathcal{F})$  zu einem Modellausschnitt  $\Omega', \mathcal{F}'$  überzugehen. Es handelt sich also um Abbildungen  $X : \Omega \rightarrow \Omega'$ . Damit wird auch jedem Er-

eignis in  $\mathcal{F}'$  eine Wert zuordnen können, benötigen wir

$$A' \in \mathcal{F}' \Rightarrow X^{-1}A' \in \mathcal{F}$$

d.h.  $X$  sollte messbar sein.

**Definition 2.1 (Zufallsvariable)**

Seien  $(\Omega, \mathcal{F})$  und  $(\Omega', \mathcal{F}')$  Ereignisräume. Dann heißt jede messbare Abbildung

$$X : \Omega \rightarrow \Omega'$$

Zufallsvariable (von  $(\Omega, \mathcal{F})$  nach  $(\Omega', \mathcal{F}')$  auf  $(\Omega', \mathcal{F}')$  oder Zufallselement.

■ **Beispiel 2.2**

1. Ist  $\Omega$  abzählbar und  $\mathcal{F} = \mathcal{P}(\Omega)$ , so ist jede Abbildung  $X : \Omega \rightarrow \Omega'$  messbar und damit eine Zufallsvariable.
2. Ist  $\Omega \subset \mathbb{R}^n$  und  $\mathcal{F} = \mathcal{B}(\Omega)$ , so ist jede stetige Funktion  $X : \Omega \rightarrow \mathbb{R}$  messbar und damit eine Zufallsvariable.

**Satz 2.3**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X$  eine Zufallsvariable von  $(\Omega, \mathcal{F})$  nach  $(\Omega', \mathcal{F}')$ . Dann definiert

$$\mathbb{P}'(A') := \mathbb{P}(X^{-1}(A')) = \mathbb{P}(\{X \in A'\}), A' \in \mathcal{F}'$$

ein Wahrscheinlichkeitsmaß auf  $(\Omega', \mathcal{F}')$  auf  $(\Omega', \mathcal{F}')$ , welches wir als Wahrscheinlichkeitsverteilung von  $X$  unter  $\mathbb{P}$  bezeichnen.

*Beweis.* Aufgrund der Messbarkeit von  $X$  ist die Definition sinnvoll. Zudem gelten

$$\mathbb{P}'(\Omega') = \mathbb{P}(X^{-1}(\Omega')) = \mathbb{P}(\Omega) = 1$$

und für  $A'_1, A'_2, \dots \in \mathcal{F}'$  paarweise disjunkt.

$$\begin{aligned} \mathbb{P}'\left(\bigcup_{i \geq 1} A'_i\right) &= \mathbb{P}\left(X^{-1}\left(\bigcup_{i \geq 1} A'_i\right)\right) \\ &= \mathbb{P}\left(\bigcup_{i \geq 1} X^{-1}(A'_i)\right) \\ &= \sum_{i \geq 1} \mathbb{P}(X^{-1}A'_i) \end{aligned}$$

da auch  $X^{-1}A'_1, X^{-1}A'_2, \dots$  paarweise disjunkt

$$= \sum_{i \geq 1} \mathbb{P}'(A'_i).$$

Also ist  $\mathbb{P}'$  ein Wahrscheinlichkeitsmaß. □

► **Bemerkung**

- Aus Gründen der Lesbarkeit schreiben wir in der Folge  $\mathbb{P}(X \in A) = \mathbb{P}(\{\omega: X(\omega) \in A\})$
- Ist  $X$  die Identität, so fallen die Begriffe Wahrscheinlichkeitsmaß und Wahrscheinlichkeitsverteilung zusammen.
- In der (weiterführenden) Literatur zu Wahrscheinlichkeitstheorie wird oft auf die Angabe eines zugrundeliegenden Wahrscheinlichkeitsraumes verzichtet und stattdessen eine “Zufallsvariable mit Verteilung  $\mathbb{P}$  auf  $\Omega$ ” eingeführt. Gemeint ist (fast) immer  $X$  als Identität auf  $(\Omega, \mathcal{F}, \mathbb{P})$  mit  $\mathcal{F} = \mathcal{P}(\Omega)/\mathcal{B}(\Omega)$ .
- Für die Verteilung von  $X$  unter  $\mathbb{P}$  schreibe  $\mathbb{P}_X$  und  $X \sim \mathbb{P}_X$  für die Tatsache, dass  $X$  gemäß  $\mathbb{P}_X$  verteilt ist.

**Definition 2.4 (identisch verteilt, reellen Zufallsvariablen)**

Zwei Zufallsvariablen sind identisch verteilt, wenn sie dieselbe Verteilung haben. Von besonderem Interesse sind für uns die Zufallsvariablen, die nach  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  abbilden, sogenannte reelle Zufallsvariablen.

Da die halboffenen Intervalle  $\mathcal{B}(\mathbb{R})$  erzeugen, ist die Verteilung einer reellen Zufallsvariable durch die Werte  $(-\infty, c], c \in \mathbb{R}$  eindeutig festgelegt.

**Definition 2.5 ((komulative) Verteilungsfunktion von  $\mathbb{P}$ )**

Sei  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$  Wahrscheinlichkeitsraum, so heißt

$$F : \mathbb{R} \rightarrow [0, 1] \text{ mit } x \mapsto \mathbb{P}((-\infty, x])$$

(komulative) Verteilungsfunktion von  $\mathbb{P}$ .

Ist  $X$  eine reelle Zufallsvariable auf beliebigem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{F}, \mathbb{P})$ , so heißt

$$F : \mathbb{R} \rightarrow [0, 1] \text{ mit } x \mapsto \mathbb{P}(X \leq x) = \mathbb{P}(X \in (-\infty, x])$$

die (komulative) Verteilungsfunktion von  $X$ .


■ **Beispiel 2.6**

Sei  $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$  mit  $\mathbb{P}$  Exponentialverteilung mit Parameter  $\lambda > 0$

$$\mathbb{P}(A) = \int_{A \cap [0, \infty)} \lambda e^{-\lambda x} dx \quad A \in \mathcal{B}(\mathbb{R}).$$

Dann ist

$$F(x) = \mathbb{P}((-\infty, x]) = \begin{cases} 0 & x \leq 0 \\ \int_0^x \lambda e^{-\lambda y} dy = 1 - e^{-\lambda x} & x > 0 \end{cases}.$$




### ■ Beispiel 2.7

Das Würfeln mit einem fairen, sechseitigen Würfel kann mittels einer reellen Zufallsvariablen

$$X : \{1, 2, \dots, 6\} \rightarrow \mathbb{R} \text{ mit } x \mapsto x$$

modelliert werden. Es folgt als Verteilungsfunktion

$$\begin{aligned} F(x) &= \mathbb{P}(X \leq x) = \mathbb{P}(X^{-1}(-\infty, x]) = \mathbb{P}((-\infty, x]) \\ &= \frac{1}{6} \sum_{i=1}^6 \mathbb{1}_{i \leq x}. \end{aligned}$$



Allgemein:

**Satz 2.8**

Ist  $\mathbb{P}$  ein Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $F$  die zugehörige Verteilungsfunktion, so gelten

1.  $F$  ist monoton wachsend
2.  $F$  ist rechtsseitig stetig
3.  $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$

Umgekehrt existiert zu jeder Funktion  $F : \mathbb{R} \rightarrow [0, 1]$  mit Eigenschaften 1-3 eine reelle Zufallsvariable auf  $((0, 1), \mathcal{B}((0, 1)), \mathbb{U}((0, 1)))$  mit Verteilungsfunktion  $F$ .

*Beweis.* Ist  $F$  Verteilungsfunktion, so folgt mit Satz 1.4

$$x \leq y \Rightarrow F(x) = \mathbb{P}((-\infty, x]) \stackrel{1.4.3}{\leq} \mathbb{P}((-\infty, y]) = F(y)$$

und

$$\lim_{x \searrow c} F(x) = \lim_{x \searrow c} \mathbb{P}((-\infty, x]) \stackrel{\sigma\text{-Stetigkeit}}{=} \mathbb{P}((-\infty, c]) = F(c)$$

sowie

$$\begin{aligned} \lim_{x \rightarrow -\infty} F(x) &\stackrel{1.4.5}{=} \mathbb{P}(\emptyset) \stackrel{1.4.1}{=} 0 \\ \lim_{x \rightarrow \infty} F(x) &\stackrel{1.4.5}{=} \mathbb{P}(\mathbb{R}) = 1. \end{aligned}$$

Umgekehrt wähle

$$X(u) := \inf\{x \in \mathbb{R} : F(x) \geq u\}, \quad u \in (0, 1)$$

Dann ist  $X$  eine “linkseitige Inverse” von  $F$  (auch Quantilfunktion / verallgemeinerte Inverse). Wegen 3 gilt:

$$-\infty < X(u) < \infty$$

und zudem

$$\{X \leq x\} = (0, F(x)) \cap (0, 1) \in \mathcal{B}((0, 1)).$$

Da diese halboffene Mengen ein Erzeugendensystem von  $\mathcal{B}(\mathbb{R})$  bilden, folgt bereits die Messbarkeit von  $X$ , also ist  $X$  eine ZV. Insbesondere hat die Menge  $\{X \leq x\}$  gerade LEBESGUE-Maß  $F(x)$  und damit hat  $X$  die Verteilungsfunktion  $F$ .  $\square$

**Folgerung 2.9**

Ist  $\mathbb{P}$  Wahrscheinlichkeitsmaß auf  $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$  und  $F$  die zugehörige Verteilungsfunktion. Dann besitzt  $\mathbb{P}$  genau eine Dichtefunktion  $\rho$ , wenn  $F$  stetig differenzierbar ist, denn dann gelten

$$F(x) = \int_{-\infty}^x \rho(x) \, dx, \text{ bzw. } \rho(x) = F'(x)$$

*Beweis.* Folgt aus Satz 1.8, der Definition 2.5 der Verteilungsfunktion und dem Eindeigkeitssatz Satz 1.9.  $\square$

## Kapitel II

# *Erste Standardmodelle der Wahrscheinlichkeitstheorie*

## Diskrete Verteilungen

### 1. Diskrete Gleichverteilungen

Erinnerung:

► **Erinnerung (Definition I.1.10)**

Ist  $\Omega$  endlich, so heißt Wahrscheinlichkeitsmaß mit Zähldichte

$$\rho(\omega) = \frac{1}{|\Omega|}, \omega \in \Omega$$

(diskrete) Gleichverteilung auf  $\Omega \rightarrow U(\Omega)$

Es gilt das für jedes  $A \in \mathcal{P}(\Omega)$

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|}$$

Anwendungsbeispiele sind faires Würfeln, fairer Münzwurf, Zahlenlotto, ...


### 2. Urnenmodelle

Ein “Urnenmodell” ist eine abstrakte Darstellung von Zufallsexperimenten, bei denen zufällig Stichproben aus einer gegebenen Menge “gezogen” werden.

**Definition (Urne)**

Eine Urne ist ein Behältnis in welchem sich farbige/nummerierte Kugeln befinden, die ansonsten ununterscheidbar sind.

Aus der Urne ziehe man blind/zufällig eine oder mehrere Kugeln und notiere Farbe/Zahl.



**Abbildung II.1:** Urnenmodell**2.1. Urnenmodell mit Zurücklegen: Multinomial-Verteilung**

Gegeben: Urne mit  $N$  Kugeln, verschiedenfarbig mit Farben aus  $E$ ,  $|E| \geq 2$

Ziehe:  $n$  Stichproben/Kugeln, wobei nach jedem Zug die Kugel wieder zurückgelegt wird. Uns interessiert die Farbe in jedem Zug, setze also

$$\Omega = E^n \text{ und } \mathcal{F} = \mathcal{P}(\Omega)$$

Zur Bestimmung einer geeigneten Wahrscheinlichkeitsmaßes, nummerieren wir die Kugeln mit  $1, \dots, N$ , so dass alle Kugeln der Farbe  $a \in E$  eine Nummer aus  $F_a \subset \{1, \dots, N\}$  tragen. Würden wir die Nummern notieren, so wäre

$$\bar{\Omega} = \{1, \dots, N\}^n \text{ und } \bar{\mathcal{F}} = \mathcal{P}(\bar{\Omega})$$

und wir könnten die Gleichverteilung  $\bar{\mathbb{P}} = \mathbf{U}(\bar{\Omega})$  als Wahrscheinlichkeitsmaß für einem einzelnen Zug verwenden. Für den Übergang zu  $\Omega$  konstruieren wir Zufallsvariablen. Die Farbe im  $i$ -ten Zug wird beschrieben durch

$$X_i : \bar{\Omega} \rightarrow E \text{ mit } \bar{\omega} = (\bar{\omega}_1, \dots, \bar{\omega}_n) \mapsto a \text{ falls } \bar{\omega}_i \in F_a$$

Der Zufallsvektor

$$X = (X_1, \dots, X_n) : \bar{\Omega} \rightarrow \Omega$$

beschreibt dann die Abfolge der Farben. Für jedes  $\omega \in \Omega$  gilt dann

$$\{X = \omega\} = F_{\omega_1} \times \dots \times F_{\omega_n} = \bigtimes_{i=1}^n F_{\omega_i}$$

und damit

$$\begin{aligned} \mathbb{P}(\{\omega\}) &= \bar{\mathbb{P}}(X^{-1}(\{\omega\})) = \bar{\mathbb{P}}(X = \omega) \\ &= \frac{|F_{\omega_1}| \cdots |F_{\omega_n}|}{|\bar{\Omega}|} \\ &= \prod_{i=1}^n \frac{|F_{\omega_i}|}{N} =: \prod_{i=1}^n \rho(\omega_i) \end{aligned}$$

Zähldichten, die sich als Produkt von Zähldichten schreiben lassen, werden auch als Produktdichten bezeichnet ( $\nearrow$  §3 Unabhängigkeit).

Sehr oft interessiert bei einem Urnenexperiment nicht die Reihenfolge der gezogenen Farben, sondern nur die Anzahl der Kugeln in Farbe  $a \in E$  nach  $n$  Zügen. Dies entspricht

$$\hat{\Omega} = \left\{ k = (k_a)_{a \in E} \in \mathbb{N}_0^{|E|} : \sum_{a \in E} k_a = n \right\} \text{ und } \hat{\mathcal{F}} = \mathcal{P}(\hat{\Omega})$$



Den Übergang  $\Omega \rightarrow \hat{\Omega}$  beschreiben wir durch die Zufallsvariablen

$$Y_a(\omega) : \Omega \rightarrow \mathbb{N}_0 \text{ mit } \omega = (\omega_1, \dots, \omega_n) \mapsto \sum_{a \in E} \mathbb{1}_{\{a\}}(\omega_i)$$

und

$$Y = (Y_a)_{a \in E} : \Omega \rightarrow \hat{\Omega} = \left\{ k = (k_a)_{a \in E} : \sum_{a \in E} k_a = n \right\}$$

Wir erhalten

$$\mathbb{P}(Y = k) = \mathbb{P}(Y_a = k_a, a \in E) \quad (1)$$

$$= \sum_{\omega \in \Omega: Y(\omega) = k} \prod_{i=1}^n \rho(\omega_i) \quad (2)$$

$$= \sum_{\omega \in \Omega: Y(\omega) = k} \prod_{a \in E} \rho(a) = \binom{n}{(k)_{a \in E}} \prod_{a \in E} \rho(a)^{k_a}$$

wobei

$$\binom{n}{(k_1, \dots, k_l)} = \begin{cases} \frac{n!}{k_1! k_2! \dots k_l!} & \sum_{i=1}^l k_i = n \\ 0 & \text{sonst} \end{cases}$$

der Multinomialkoeffizient ist, welcher die Anzahl der Möglichkeiten beschreibt,  $n$  Objekte in  $l$  Gruppen aufzuteilen, so dass Gruppe  $i$  gerade  $k_i$  Objekte beinhaltet.

### Definition 2.1

Sei  $l > 2, p = (p_1, \dots, p_l)$  eine Zähldichte und  $n \in \mathbb{N}$ , dann heißt die Verteilung auf

$\{k = (k_i)_{i=1, \dots, l} \in \mathbb{N}_0^l : \sum_{i=1}^l k_i = n\}$  mit Zähldichte

$$m((k_1, \dots, k_l)) = \binom{n}{k_1, \dots, k_l} \prod_{i=1}^l p_i^{k_i}$$

Multinomialverteilung mit Parametern  $n$  und  $p$ . Wir schreiben auch  $\text{Multi}(n, p)$ .

### ■ Beispiel 2.2

Eine Urne enthalte nur schwarze “1” und weiße “0” Kugeln, d.h.  $E = \{0, 1\}$ , und es sei  $\rho(1) = p$  gerade die Proportion der schwarzen Kugeln (= Wahrscheinlichkeit bei einem Zug schwarz zu ziehen), dann ist Wahrscheinlichkeit in  $n$  Zügen  $k$ -mal schwarz zu ziehen:

$$\binom{n}{k} \prod_{i=0,1} \rho(i)^{k_i} = \binom{n}{k} p^k (1-p)^{n-k}.$$

Ein solches (wiederholtes) Experiment mit nur zwei möglichen Ereignissen und fester Wahrscheinlichkeit  $p \in [0, 1]$  für eines der Ergebnisse nennen wir auch (wiederholtes) Bernoulliexperiment.

**Definition 2.3**

Sei  $p \in [0, 1]$  und  $n \in \mathbb{N}$ , dann heißt die Verteilung mit Zähldichte

$$\rho(k) = \binom{n}{k} p^k (1-p)^{n-k} \text{ mit } k \in \{0, 1, \dots, n\}.$$

Binomialverteilung auf  $\{0, \dots, n\}$  mit Parameter  $p$  (auch Erfolgswahrscheinlichkeit). Wir schreiben auch  $\text{Bin}(n, p)$ . Im Fall  $n = 1$  nennen wir die Verteilung mit Zähldichte

$$\rho(0) = 1 - p \text{ und } \rho(1) = p$$

auch Bernoulliverteilung mit Parameter  $p$  und schreiben  $\text{Bernoulli}(p)$ .

Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung

Gegeben: Urne mit  $N$  Kugeln verschiedener Farben aus  $E$ ,

$$|E| \geq 2.$$

Es werden  $n \leq N$  Stichproben entnommen, wobei die gezogenen Kugeln nicht in die Urne zurückgelegt.

## 2.2. Urnenmodell ohne Zurücklegen: Hypergeometrische Verteilung

Gegeben: Urne mit  $N$  Kugeln verschiedener Farben aus  $E$ ,  $|E| \geq 2$ . Es werden  $n \leq N$  Stichproben entnommen, wobei die gezogenen Kugeln nicht in die Urne zurückgelegt.

### ■ Beispiel 2.4

Eine Urne enthalte  $S$  schwarze “1” und  $W$  weiße Kugeln “0” Kugeln, ( $E = \{0, 1\}, S + W = N$ ). Dann ist die Wahrscheinlichkeit in  $n$  Zügen ohne Zurücklegen gerade  $s$  schwarze und  $w$  weiße Kugeln zu ziehen

$$\rho(w) = \frac{\binom{W}{w} \binom{S}{s}}{\binom{N}{n}}, \quad 0 \leq s \leq S, 0 \leq w \leq W, s + w = n, S + W = N.$$

*Beweis.* Hausaufgabe!

□

**Definition 2.5**

Seien  $N \in \mathbb{N}, W \leq N, n \leq N$ , dann heißt die Verteilung auf  $\{0, \dots, n\}$  mit Zähldichte

$$\rho(w) = \frac{\binom{W}{w} \binom{N-W}{n-w}}{\binom{N}{n}}, \quad w = \max\{0, n - N + W\}, \dots, \min\{W, n\},$$

die Hypergeometrische Verteilung mit Parametern  $N, W, n$ . Wir schreiben  $\text{Hyper}(N, W, n)$ .

## 3. Poisson-Approximation und Poisson-Verteilung

$\text{Bin}(n, p)$  ist zwar explizit und elementar definiert, jedoch für große  $n$  mühsam auszuwerten. Für seltene Ereignisse ( $n$  groß,  $p$  klein) verwende daher:

**Satz 3.1 (Poisson-Approximation)**

Sei  $\lambda > 0$  und  $(p_n)_{n \in \mathbb{N}}$  eine Folge in  $[0, 1]$  mit

$$np_n \rightarrow \lambda, \quad n \rightarrow \infty.$$

Dann gilt  $\forall k \in \mathbb{N}_0$  für die Zähldichte der  $\text{Bin}(n, p_n)$ -Verteilung

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = e^{-\lambda} \frac{\lambda^k}{k!}.$$

*Beweis.* Sei  $k \in \mathbb{N}_0$  fix, dann

$$\begin{aligned} \binom{n}{k} &= \frac{n!}{k!(n-k)!} = \frac{n^k}{k!} \frac{n(n-1) \cdots (n-k+1)}{n^k} \\ &= \frac{n^k}{k!} \cdot 1 \cdot \left(1 - \frac{1}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \\ &\stackrel{n \rightarrow \infty}{\sim} \frac{n^k}{k!}, \end{aligned}$$

wobei  $a(l) \stackrel{n \rightarrow \infty}{\sim} b(l) \Leftrightarrow \frac{a(l)}{b(l)} \xrightarrow{n \rightarrow \infty} 1$ . Damit

$$\begin{aligned} \binom{n}{k} p_n^k (1 - p_n)^{n-k} &\stackrel{n \rightarrow \infty}{\sim} \frac{n^k}{k!} p_n^k (1 - p_n)^{n-k} \\ &\stackrel{n \rightarrow \infty}{\sim} \frac{\lambda^k}{k!} (1 - p_n)^n \\ &= \frac{\lambda^n}{k!} \left(1 - \frac{np_n}{n}\right)^n \\ &\xrightarrow{n \rightarrow \infty} \frac{\lambda^n}{k!} e^{-\lambda}. \end{aligned}$$

□

Der erhaltene Grenzwert liefert die Zähldichte auf  $\mathbb{N}_0$ , denn

$$\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} e^{\lambda} = 1$$

**Definition 3.2**

Sei  $\lambda > 0$ . Dann heißt das auf  $(\mathbb{N}_0, \mathbb{P}(\mathbb{N}_0))$  definiert Wahrscheinlichkeitsmaß mit

$$\mathbb{P}(\{k\}) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k \in \mathbb{N}_0,$$

Poissonverteilung mit Parameter  $\lambda$ . Schreibe  $\text{Poisson}(\lambda)$ .

Die Poissonverteilung ist ein natürliches Modell für die Anzahl von zufälligen, seltenen Ereignissen (z.B. Tore im Fußballspiel, Schadensfälle einer Versicherung, ...).

## Kapitel III

# *Bedingte Wahrscheinlichkeiten und (Un)-abhängigkeit*

## 1. Bedingte Wahrscheinlichkeiten

### ■ Beispiel 1.1

Das Würfeln mit zwei fairen, sechseitigen Würfeln können wir mit

$$\Omega = \{(i, j), i, j \in \{1, \dots, 6\}\}$$

und  $\mathbb{P} = \mathbb{U}(\Omega)$ . Da  $|\Omega| = 36$  gilt also

$$\mathbb{P}(\{\omega\}) = \frac{1}{36} \quad \forall \omega \in \Omega.$$

Betrachte das Ereignis

$$A = \{(i, j) \in \Omega : i + j = 8\},$$

dann folgt

$$\mathbb{P}(A) = \frac{5}{36}.$$

Werden die beiden Würfel nach einander ausgeführt, so kann nach dem ersten Wurf eine Neubewertung der Wahrscheinlichkeit von  $A$  erfolgen.

Ist z.B.:

$$B = \{(i, j) \in \Omega, i = 4\}$$

eingetreten, so kann die Summe 8 nur durch eine weitere 4 realisiert werden, also mit Wahrscheinlichkeit

$$\frac{1}{6} = \frac{|A \cap B|}{|B|}.$$

Das Eintreten von  $B$  führt also dazu, dass das Wahrscheinlichkeitsmaß  $\mathbb{P}$  durch ein neues Wahrscheinlichkeitsmaß  $\mathbb{P}_B$  ersetzt werden muss. Hierbei sollte gelten:

Renormierung:  $\mathbb{P}_B = 1$  (R)

Proportionalität: Für alle  $A \subset \mathcal{F}$  mit  $A \subseteq B$  gilt  $\mathbb{P}_B(A) = c_B \mathbb{P}(A)$  mit einer Konstante  $c_B$ . (P)

**Lemma 1.2**

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $B \in \mathcal{F}$  mit  $\mathbb{P}(B) > 0$ . Dann gibt es genau ein Wahrscheinlichkeitsmaß  $\mathbb{P}_B$  auf  $(\Omega, \mathcal{F})$  mit den Eigenschaften (R) und (P). Dieses ist gegeben durch

$$\mathbb{P}_B(A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} \quad \forall A \in \mathcal{F}.$$

*Beweis.* Offenbar erfüllt  $\mathbb{P}_B$  wie definiert (R) und (P). Umgekehrt erfüllt  $\mathbb{P}_B$  (R) und (P). Dann folgt für  $A \in \mathcal{F}$ :

$$\mathbb{P}_B(A) = \mathbb{P}_B(A \cap B) + \underbrace{\mathbb{P}_B(A \setminus B)}_{=0, \text{ wegen (R)}} \stackrel{(P)}{=} c_B \mathbb{P}(A \cap B).$$

Für  $A = B$  folgt zudem aus (R)

$$1 = \mathbb{P}_B(B) = c_B \mathbb{P}(B)$$

also  $c_B = \mathbb{P}(B)^{-1}$ . □

## Kapitel IV

### *Test*

# Anhang

# Index

- (absolut)stetig (bzgl. denn Lebesgue-Maß), 7
- (diskrete) Gleichverteilung, 8, 13
- (komulative) Verteilungsfunktion von  $\mathbb{P}$ , 10
- (stetige) Gleichverteilung, 8
- (wiederholtes) Bernoulliexperiment, 15
- DIRAC-Maß, 6
- DIRAC-Verteilung, 6
- KOLMOGOROVsche Axiome, 5
  
- BernoulliVerteilung mit Parameter  $p$ , 16
- Binomialverteilung auf  $\{0, \dots, n\}$  mit  
Parameter  $p$ , 16
  
- Dichte, 7
- Dichtefunktion, 7
  
- Ereignisraum, 4
- Erfolgswahrscheinlichkeit, 16
- Ergebnisraum, 4
- Exponentialverteilung, 7
  
- Hypergeometrische Verteilung, 16
  
- identisch verteilt, 10
  
- messbar, 4
- messbarer Raum, 4
- Multinomialkoeffizient, 15
- Multinomialverteilung mit Parametern  $n$  und  
 $p$ , 15
  
- Poissonverteilung mit Parameter  $\lambda$ , 17
- Produktdichten, 14
  
- Quantilfunktion, 12
  
- reelle Zufallsvariablen, 10
  
- verallgemeinerte Inverse, 12
  
- Wahrscheinlichkeitsdichte, 7
- Wahrscheinlichkeitsmaß, 5
- Wahrscheinlichkeitsraum, 8
- Wahrscheinlichkeitsverteilung, 5
- Wahrscheinlichkeitsverteilung von  $X$  unter  $\mathbb{P}$ , 9
  
- Zähldichte, 7
- Zufallselement, 9